Relatório de Laboratório 03

Métricas DORA em repositórios do GitHub

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab03 — Métricas DORA no GitHub
Grupo (trio)	Fernanda Soares · Islayder Jackson · Vinicius Gomes
Link do repositório / GitHub Projects	https://github.com/fesoaress/Laboratorio-Medicao-e-experimentacao
Data de entrega	22/10/2026

1. Introdução

Métricas DORA ajudam a descrever a velocidade e a estabilidade da entrega de software, mas o GitHub não expõe diretamente implantações em produção ou incidentes operacionais (Forsgren, Humble e Kim, 2018). Este estudo mede proxies observáveis em repositórios públicos: releases, commits e execuções do GitHub Actions. A pergunta central é quanto as conclusões mudam quando alteramos a definição operacional da métrica.

Investigamos 311 repositórios na janela UTC de 01/10/2025 a 30/09/2026. A unidade estatística é o repositório. Além das sete questões do enunciado, analisamos retrabalho corretivo (RQ08) e estimamos intervalos de confiança por bootstrap de repositórios. Estas eram as hipóteses informais registradas antes da análise:

- RQ01 — A frequência seria geralmente inferior a uma release por semana.
- RQ02 — O lead time por commit teria mediana maior e dispersão mais alta que por release.
- RQ03 — A taxa de falha de CI seria maior que a taxa de falha de entrega.
- RQ04 — A recuperação ocorreria em horas, com censura não desprezível.
- RQ05 — A associação entre frequência e falha seria nula ou levemente negativa.
- RQ06 — Popularidade e contribuidores se associariam a melhor desempenho.
- RQ07 — As definições teriam concordância moderada a substancial, com CFR mais instável.

RQ08 é exploratória: descreve a proporção de releases corretivas sem hipótese confirmatória. A linguagem de programação, aventada no rascunho inicial, não foi testada; os fatores efetivamente analisados foram estrelas, contribuidores e idade.

2. Contexto

O Lab03 articula coleta, validação humana, construção de métricas e inferência estatística em três sprints. Na S01, o grupo estruturou a seleção e a coleta; na S02, consolidou a amostra de 311 elegíveis e a referência para releases corretivas; na S03, executou descrições, testes, sensibilidade e bootstrap. Os scripts REST/GraphQL são próprios do grupo, como exige o enunciado; ferramentas estatísticas foram usadas apenas após a coleta.

O objeto de estudo são projetos públicos com mais de mil estrelas, Actions, branch principal identificada, pelo menos cinco releases estáveis ancestrais e 50 runs válidos de push. Uma GitHub Release pode ser documentação, pacote ou entrega, sem provar implantação a usuários. Essa diferença orienta a interpretação de todas as RQs (GitHub, 2026).

3. Metodologia

3.1 Principais Desafios

A coleta exigiu paginação, cache, retomada e tratamento de limites da API. Quando tags reescritas ou removidas impedem a comparação de commits, o intervalo é registrado e excluído do LT. Para TR, uma falha sem sucesso posterior é registrada como censurada; para CFR(b), releases próximas ao fim da janela seguem a regra de observação completa. CI, release corretiva e incidente real recebem definições operacionais distintas.

A rotulagem de 60 projetos e 300 releases por três avaliadores produziu concordância de Fleiss de 0,8629 para tipo, 0,1540 para entrega real e 0,7353 para caráter corretivo. O resultado de entrega real documenta a interpretação desse critério na amostra. A heurística final (v5) atingiu precisão 0,6975, recall 0,7545 e F1 0,7249 frente ao consenso da amostra-ouro.

3.2 Tomadas de Decisão

A janela é [01/10/2025, 01/10/2026), em UTC, com fim exclusivo. O funil exige releases estáveis na definição principal; pré-releases e tags entram apenas nas variantes de sensibilidade. DF é eventos por semana ou por 30 dias; LT(a) resume, por intervalo, o tempo desde o commit mais antigo; LT(b) usa todos os pares commit–entrega. Durações negativas ou comparações inválidas são ausentes, nunca zero.

CFR(a) = falhas / (falhas + sucessos) dos runs válidos. CFR(b) classifica uma release original como falha quando há corretiva estritamente posterior em até sete dias; originais sem observação completa ao fim da janela são censuradas. TR vai da falha ao sucesso seguinte no mesmo workflow e é agregado pela mediana. A categoria geral exige quatro métricas válidas e combina seus escores pelo piso da mediana. Os limiares seguem o protocolo do laboratório.

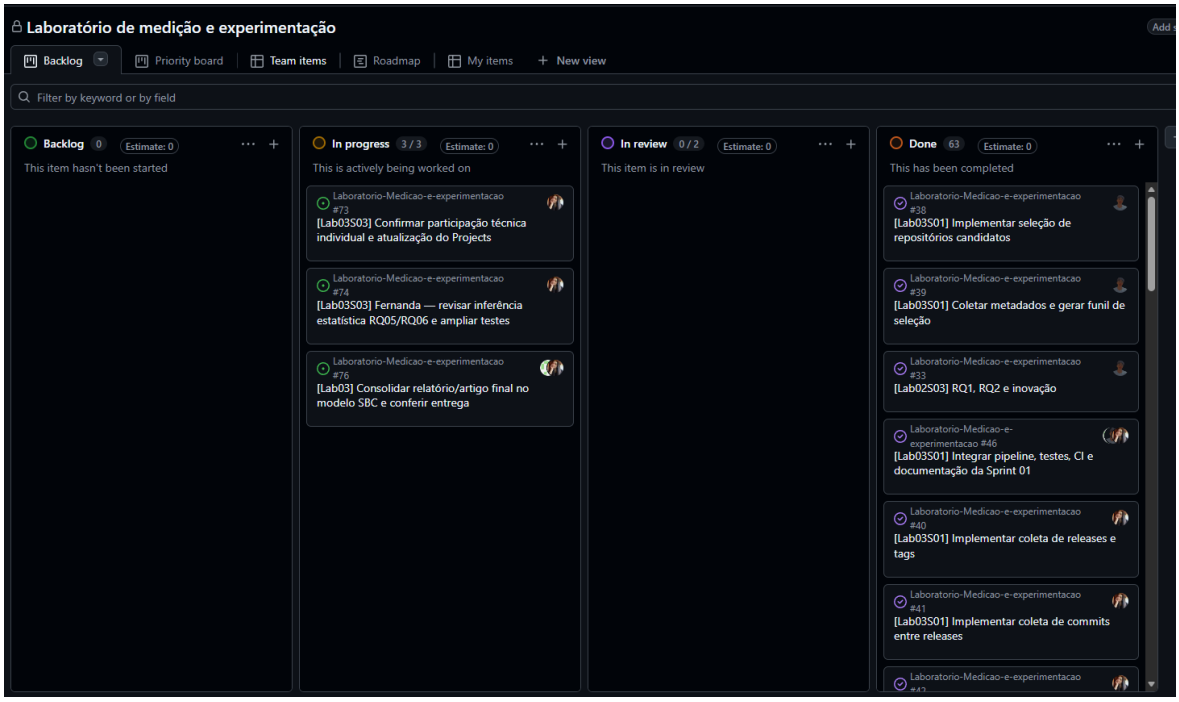
3.3 Etapas

Etapa	Entregas efetivas	Responsabilidade registrada
S01	Seleção e funil; releases/tags/commits; runs, cache; métricas iniciais	Islayder: seleção; Fernanda: releases, commits e LT; Vinicius: runs/cache/CFR(a)/TR; integração do grupo
S02	311 elegíveis; amostra-ouro e consenso; heurística corretiva; dataset	Rotulagem independente do trio; Fernanda: heurística corretiva (#58); consenso coordenado por Islayder (#57)
S03	Inferência RQ05/RQ06; bootstrap; coleta de fronteira; testes; relatório	Islayder: inferência, bootstrap e figuras (#64/#65/#67/#69/#72); Vinicius: correções e testes de coleta (#75); Fernanda: testes inferenciais (#74) e relatório (#76)

3.4 Ferramentas

Scripts Python próprios consultam GitHub REST/GraphQL e registram cache, paginação e retomada. Pandas/NumPy preparam o dataset; SciPy executa Spearman, Kruskal–Wallis e Mann–Whitney; statsmodels corrige p-valores por Holm; scikit-learn calcula Kappa; Matplotlib produz as figuras. GitHub Projects organiza as Issues. Os dados processados, resultados e manifests de SHA estão versionados na branch Laboratorio-3.

O quadro GitHub Projects do grupo está em https://github.com/users/fesoaress/projects/5. A visão Kanban apresenta Backlog, In progress, In review e Done. Os limites WIP exibidos são três itens em In progress e dois em In review; na conferência do quadro, os contadores eram 0, 3/3, 0/2 e 63, respectivamente. Os itens avançam conforme o status das Issues. Fonte: quadro do projeto, consultado em 21/10/2026.



Quadro 1. Captura da visão Kanban do GitHub Projects do grupo, com colunas e limites WIP. Fonte: quadro do projeto, 21/10/2026.

3.5 Tabela de Métricas

RQ	Métrica	Definição operacional	Unidade	Fonte
01	DF	Releases estáveis na janela × 7/365; variante por 30 dias = × 30/365	/semana	GitHub Releases
02	LT(a)/(b)	Horas do commit até a release; (a) mediana do commit mais antigo por intervalo; (b) todos os pares	horas	Compare/commits
03	CFR(a)/(b)	(a) falhas/(falhas+sucessos) de runs; (b) originais seguidas por corretiva em até 7 dias	fração	Actions/releases
04	TR	Falha até sucesso seguinte no mesmo workflow; mediana por repositório	horas	Actions
05	ρ de Spearman	Correlação DF×CFR(a/b), com 9.999 permutações e Holm	−1 a 1	dataset S02
06	Efeito ε^2	Kruskal–Wallis por quartis de estrelas, contribuidores e idade; $\varepsilon^2 = H/(n-1)$	fração	dataset S02
07	Sensibilidade	Mudança de categoria e Kappa ponderado nas interseções pareadas C1/C2/C3	contagem/κ	variantes S03
08	Retrabalho	Releases corretivas / releases estáveis; limites para classificações ausentes	fração	releases S02

3.6 Inovações Propostas pelo Grupo

A contribuição adicional quantifica a incerteza amostral por 2.000 reamostragens de repositórios (seed 42), preservando pares nas correlações. Os intervalos percentis de 95% cobrem as medianas DF, CFR(a), CFR(b) e os dois coeficientes de Spearman; réplicas indefinidas são excluídas e contadas. Essa análise complementa, sem substituir, os testes exigidos. A RQ08 acrescenta retrabalho corretivo e limites de identificabilidade quando faltam classificações; esses limites não são intervalos de confiança.

4. Resultados

4.1 Coleta de Dados

O funil começou com 1.782 candidatos únicos e terminou com 311 repositórios elegíveis. Houve 27.152 releases estáveis e 494.200 workflow runs coletados, dos quais 454.382 válidos. A amostra de referência incluiu 60 projetos e cinco releases sorteadas por projeto. Os n efetivos variam por métrica: LT, 261; TR, 286; DF e CFR, 311. Exclusões e censuras são relatadas junto às estimativas, sem preenchimento por zero.

Etapa do funil	Aprovados	Descartados	Não medidos
Candidatos únicos	1.782	0	0
Com Actions	741	207	834
Com releases estáveis	493	248	0
Ancestralidade válida	379	72	42
Runs válidos	311	67	1
Amostra final	311	1.469	2

Fonte: funil S02. “Não medido” indica ausência de avaliação naquela etapa, não resultado negativo.

4.1.1 Distribuição das métricas e da classificação geral

Métrica	n	Ausentes	Mediana	Q1	Q3	IQR
DF (/sem.)	311	0	0,326	0,153	0,710	0,556
LT(a) (h)	261	50	179,67	44,90	526,77	481,87
LT(b) (h)	261	50	118,17	27,72	425,64	397,93
CFR(a)	311	0	0,053	0,022	0,114	0,093
CFR(b)	311	0	0,227	0,083	0,472	0,388
TR (h)	286	25	3,30	0,83	18,80	17,97

Fonte: descriptive.csv. Quartis pelo método tipo 7; CFR em frações de 0 a 1. IQR = Q3 − Q1. Os n correspondem a repositórios, não a eventos.

Categoria DORA geral	Repositórios	Parcela dos 311
Low	21	6,8%
Medium	93	29,9%
High	111	35,7%
Elite	14	4,5%
Sem classificação completa	72	23,2%

A categoria geral só é atribuída quando as quatro métricas necessárias são válidas: 239 projetos classificados e 72 sem classificação completa. Fonte: dora_distribution.csv.

4.2 Visualização Gráfica

Cada figura abaixo responde diretamente à pergunta indicada. Os pontos representam projetos, as linhas de referência identificam limiares ou igualdade e as anotações mostram medianas e n. Todas as figuras derivam dos arquivos em data/processed/s02 e data/processed/s03.

RQ01 — Qual é a frequência de entrega?

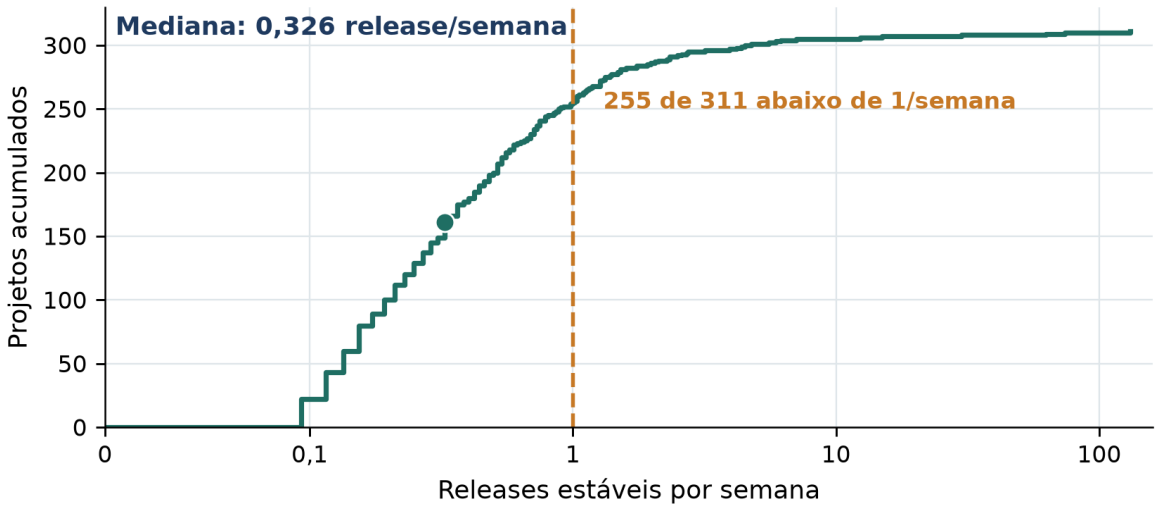


Figura 1. Frequência acumulada; escala horizontal não linear com rótulos em releases/semana. Fonte: dataset S02.

A mediana é 0,326 release/semana. Em 255/311 projetos (82,0%), a frequência é inferior a uma release semanal; o máximo é 131,10.

RQ02 — Quanto tempo levam as mudanças até a entrega?

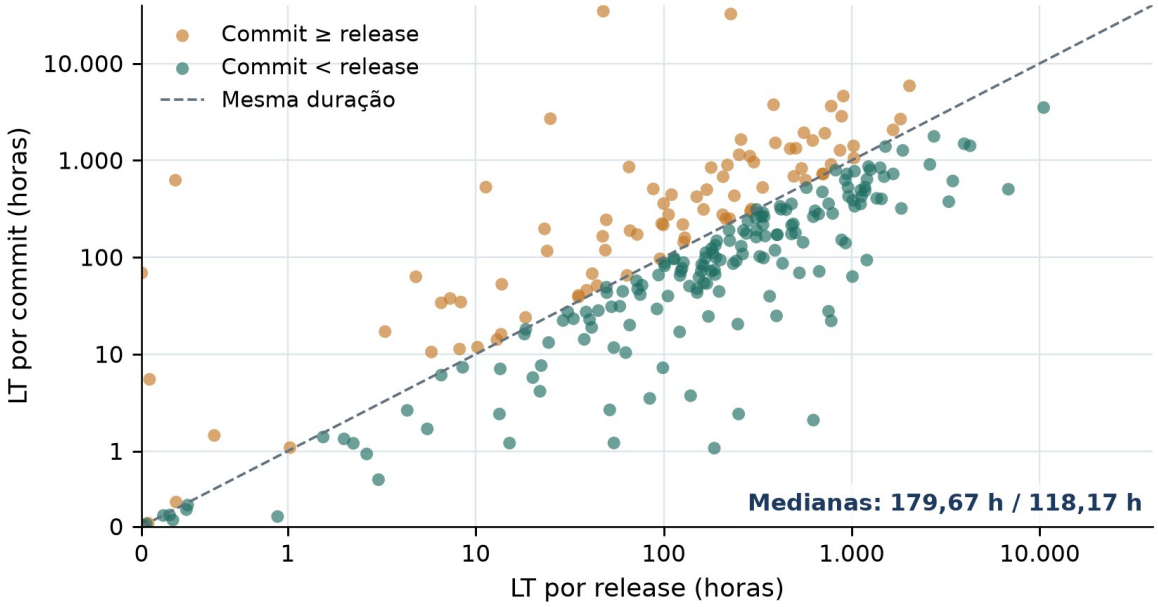


Figura 2. Cada ponto é um dos 261 projetos com os dois LT válidos; linha tracejada = igualdade. Fonte: dataset S02.

O LT por commit tem mediana 118,17 h, abaixo das 179,67 h por release; foi menor em 171 pares, igual em cinco e maior em 85. Faltam 50 projetos por erros de comparação ou métrica.

RQ03 — Qual é a taxa de falha?

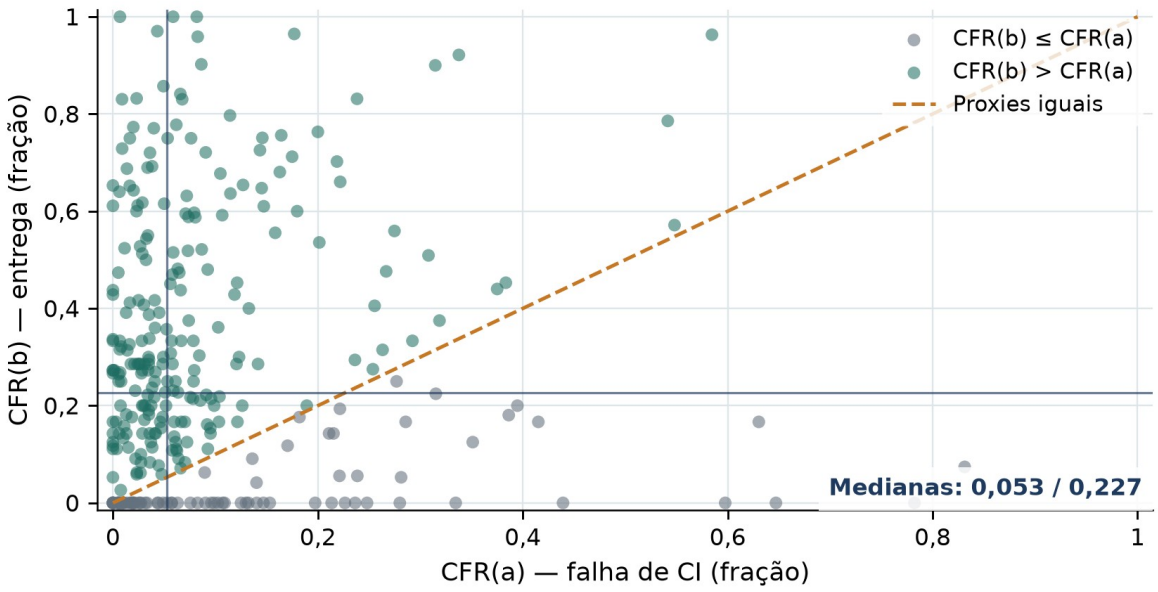


Figura 3. Comparação pareada das duas proxies; linhas sólidas nas medianas e tracejada na igualdade. Fonte: dataset S02.

As medianas são 0,0529 para CFR(a) e 0,2273 para CFR(b). CFR(b) supera CFR(a) em 228/311 projetos. A razão agregada de eventos é 75,78% e não equivale à mediana por projeto.

RQ04 — Quanto tempo leva a recuperação?

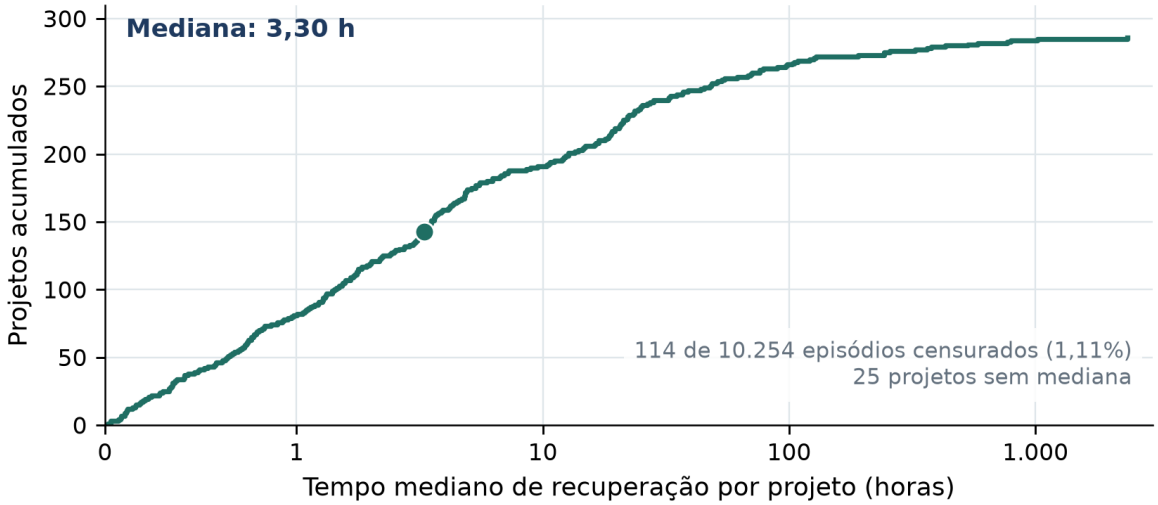


Figura 4. Distribuição acumulada de medianas por projeto; episódios censurados excluídos da mediana. Fonte: dataset S02.

TR tem mediana de 3,30 h em 286 projetos. Dos 10.254 episódios, 114 são censurados à direita (1,11%); 25 projetos não têm mediana.

RQ05 — Frequência de entrega se associa à taxa de falha?

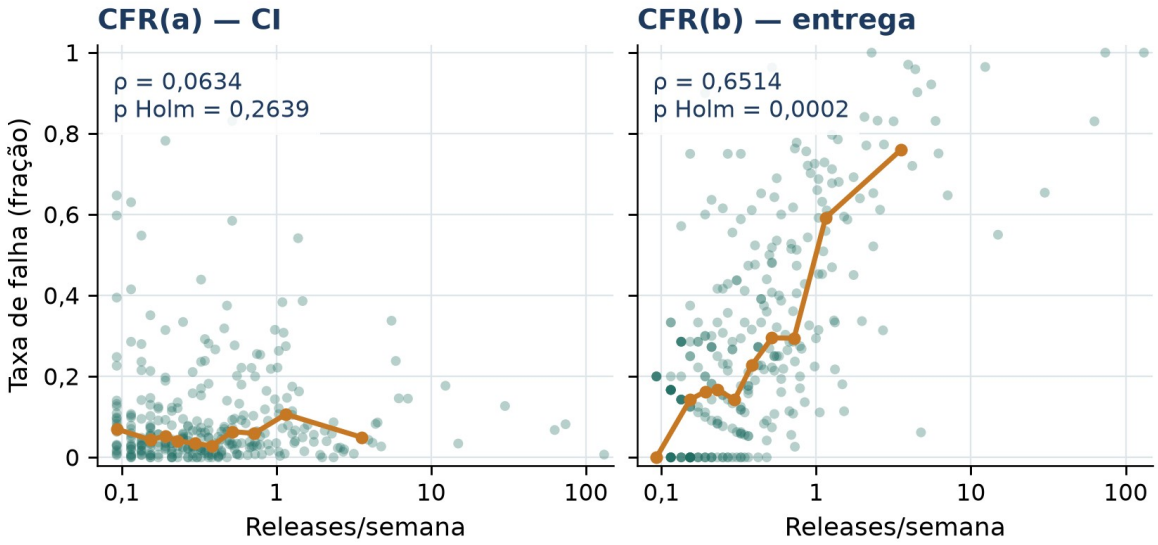


Figura 5. Pontos = projetos; linha laranja = mediana descritiva em grupos de DF. p de permutação corrigido por Holm. Fonte: spearman.csv.

Para DF×CFR(a), ρ=0,0634 e p Holm=0,2639. Para DF×CFR(b), ρ=0,6514 e p Holm=0,0002. A diferença entre proxies impede concluir uma relação causal geral.

RQ06 — Estrelas, contribuidores e idade estão associados às métricas?

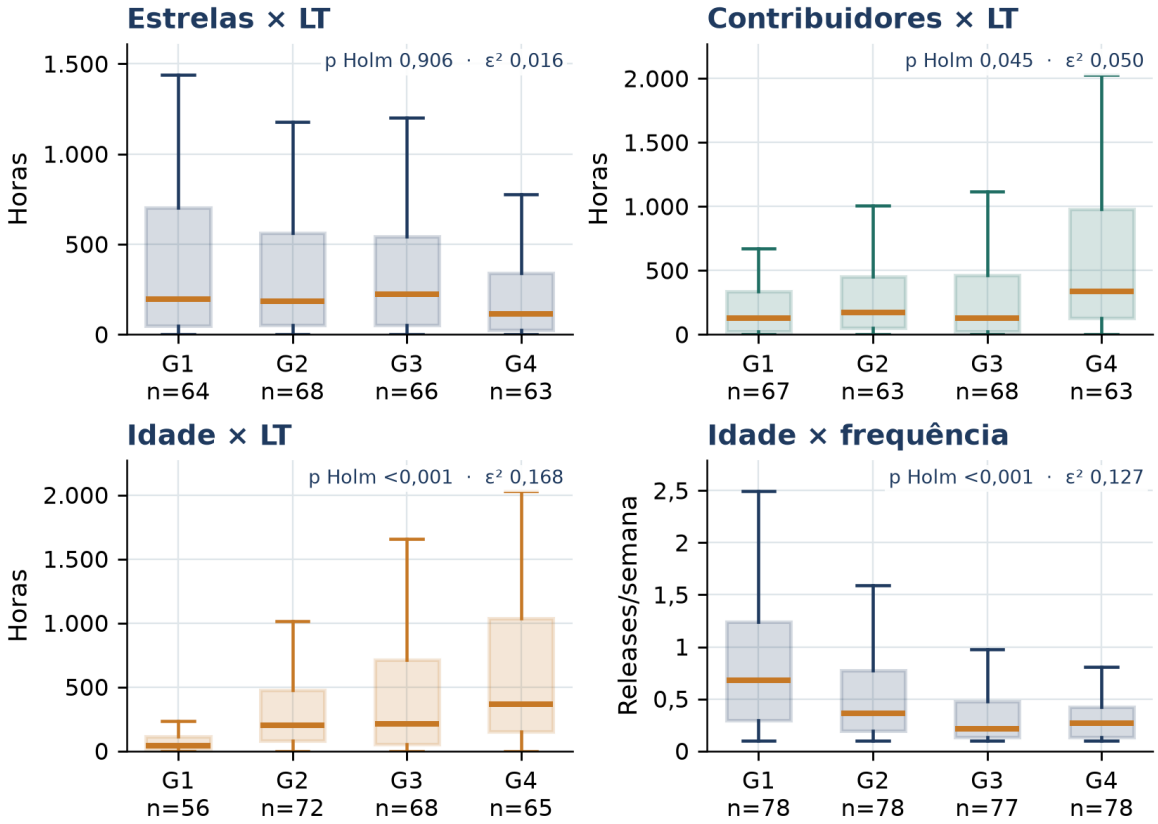


Figura 6. G1–G4 ordenam o fator do menor ao maior valor. Caixa = Q1–Q3; linha laranja = mediana; bigodes até 1,5 IQR. Extremos além dos bigodes são omitidos apenas da figura. p Holm e ε² descrevem o teste global. Fonte: dataset S02 e factor_tests.csv.

G1 reúne projetos com menos estrelas, contribuidores ou idade; G4, os de maior valor. Cada painel mostra a distribuição dos projetos, em horas de LT ou releases por semana. Para contribuidores, a mediana de LT vai de 126,34 h em G1 a 339,18 h em G4 (p Holm=0,0452). A idade também se associa a LT e frequência; estrelas não mantiveram evidência após Holm. Os testes usam todos os valores, inclusive os extremos ocultos no desenho.

RQ07 — Quanto as conclusões mudam com a definição adotada?

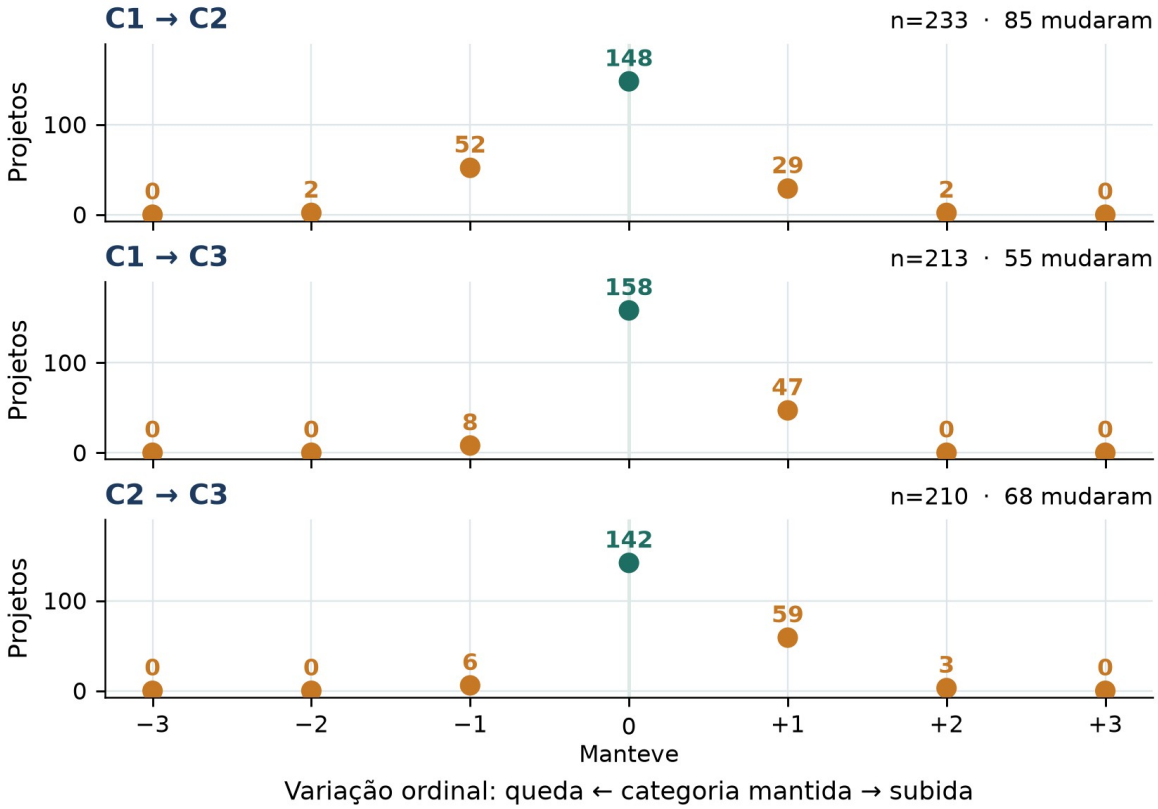


Figura 7. Contagens por variação ordinal da categoria geral; C1/C2, C1/C3 e C2/C3 usam interseções pareadas próprias. Fonte: sensitivity.csv e variant_classifications.csv.

A categoria geral mudou em 85/233 projetos (36,48%) entre C1/C2, 55/213 (25,82%) entre C1/C3 e 68/210 (32,38%) entre C2/C3. Os Kappas ponderados foram 0,475, 0,669 e 0,553.

RQ08 — Que parcela das releases é predominantemente corretiva?

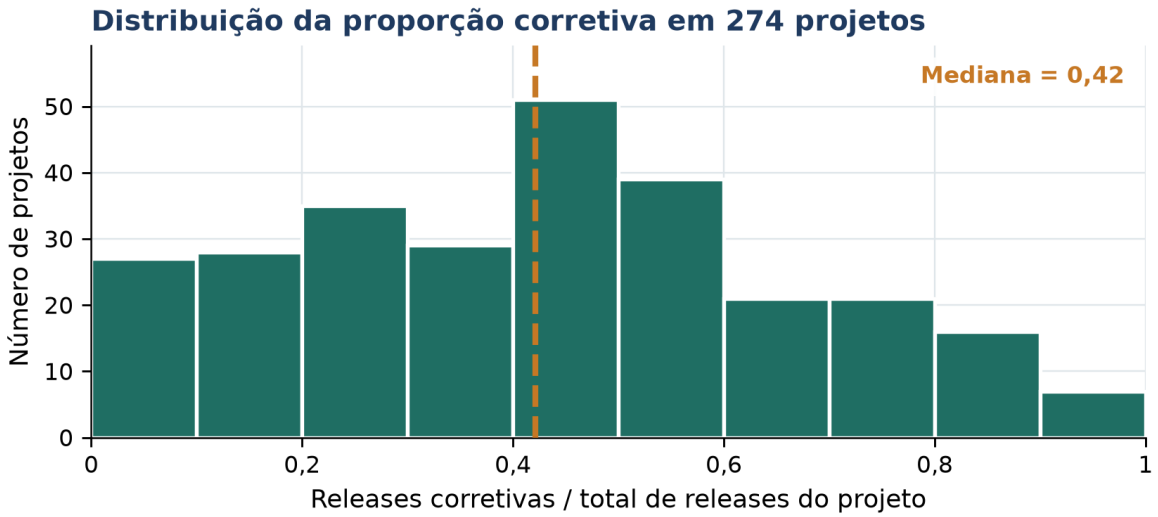


Figura 8. Cada coluna conta projetos em uma faixa da proporção de releases corretivas; a linha tracejada marca a mediana. Inclui os 274 projetos com taxa completa. Fonte: rework.csv.

No projeto mediano, 0,4211 das releases (cerca de 42 em cada 100) foram classificadas como corretivas. O gráfico mostra quantos dos 274 projetos têm proporção baixa ou alta: quanto mais alta a coluna, mais projetos naquela faixa. Outros 37 projetos não têm taxa pontual por classificações ausentes.

Inovação — Quanta incerteza amostral existe nas associações?

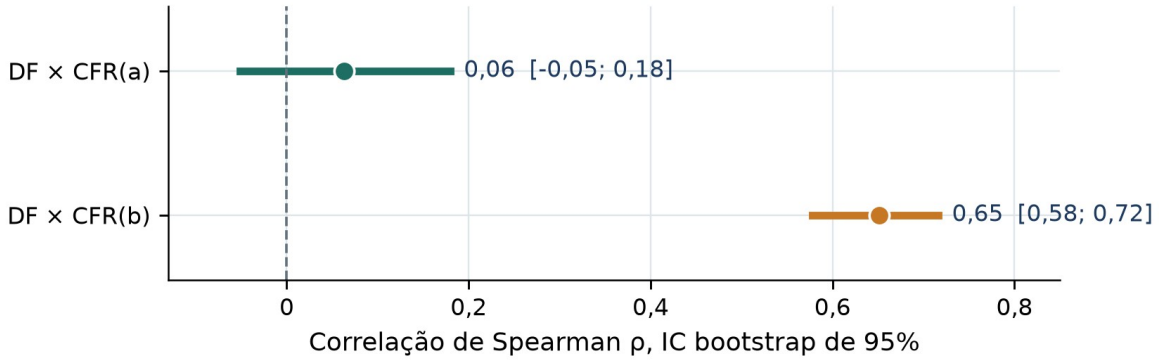


Figura 9. Estimativa e IC percentil de 95% de Spearman; 2.000 reamostragens de repositórios. Fonte: bootstrap.csv.

O IC de DF×CFR(a) é [−0,0515; 0,1797] e inclui zero; o de DF×CFR(b) é [0,5776; 0,7163] e permanece positivo. O bootstrap não corrige seleção ou erro das proxies.

Estimativa	Valor	IC95% inferior	IC95% superior
Mediana DF (/sem.)	0,3260	0,2877	0,3644
Mediana CFR(a)	0,0529	0,0433	0,0611
Mediana CFR(b)	0,2273	0,2000	0,2727
ρ DF×CFR(a)	0,0634	-0,0515	0,1797
ρ DF×CFR(b)	0,6514	0,5776	0,7163

Fonte: bootstrap.csv. IC percentil de 95%; 2.000 reamostragens válidas de 311 repositórios (seed 42). Valores de CFR em frações de 0 a 1; ρ é adimensional.

4.3 Discussão

RQ01 confirma a expectativa de frequência geralmente inferior a uma release por semana. RQ02 contradiz a direção prevista: o tempo do commit mais antigo faz LT por release superar LT por commit na mediana. RQ03 também contradiz a hipótese: a proxy de entrega corretiva é maior que a de falha de CI em grande parte dos projetos. A janela de sete dias pode acoplar CFR(b) à frequência, porque mais publicações criam mais oportunidades de associação temporal.

RQ04 indica recuperação típica em horas, com 114 episódios censurados registrados separadamente. Em RQ05, DF×CFR(a) não apresentou associação estatística, enquanto DF×CFR(b) apresentou associação positiva. Em RQ06, idade e LT por contribuidores mostraram diferenças entre grupos; a mediana de LT foi maior entre projetos com mais contribuidores. Estrelas não apresentaram evidência após a correção de Holm.

RQ07 encontrou concordância moderada a substancial na categoria geral e mudanças de classe em 25,82%–36,48% dos pares. RQ08 descreve a proporção corretiva das releases por projeto. Os intervalos bootstrap complementam os testes ao mostrar a precisão amostral estimada para as correlações.

5. Ameaças à validade

Construto. Releases, tags e runs são proxies de entrega e falha; não comprovam implantação nem incidentes em produção. A concordância sobre “entrega real” na amostra-ouro foi baixa (Kappa de Fleiss = 0,1540), e a janela de sete dias condiciona CFR(b).

Interna. A heurística v5 foi refinada e avaliada sobre o mesmo consenso de 300 releases, o que pode favorecer o F1 observado. Datas autorais, tags reescritas e critérios de ancestralidade também afetam o LT; idade e complexidade podem confundir associações entre fatores e métricas.

Externa. Os 311 projetos populares, com Actions e volume mínimo de releases e runs, não representam todo o GitHub nem organizações que registram incidentes fora da plataforma. A amostra de 60 projetos não autoriza extrapolar seus tipos para os demais.

Conclusão estatística. LT está ausente em 50 projetos e TR em 25; episódios sem recuperação são censurados e excluídos da mediana. As comparações de sensibilidade usam conjuntos pareados de tamanhos diferentes. Holm trata as famílias declaradas, enquanto bootstrap e permutações pressupõem repositórios independentes.

A reexecução em exportação limpa do Git reproduziu 18 tabelas e 27 imagens byte a byte; nove testes de auditoria passaram. Até esta versão, não há registro de replicação cruzada executada por outro grupo. Fonte: reports/s03/final_audit.md.

6. Conclusão

O estudo reuniu coleta própria, rotulagem, métricas e análise estatística reproduzível em 311 repositórios. A entrega típica foi inferior a uma release por semana; o lead time variou conforme a forma de agregação, e a associação entre frequência e falha dependeu da proxy. As comparações de sensibilidade mostraram mudanças de categoria entre definições, enquanto o bootstrap quantificou a precisão das correlações observadas.

O relatório apresenta uma figura para cada questão de pesquisa, além dos resultados da amostra-ouro e dos testes inferenciais. O pipeline, os dados processados, as figuras e os manifests estão disponíveis na branch Laboratorio-3 do repositório indicado na capa.

7. Referências

FORSGREN, N.; HUMBLE, J.; KIM, G. Accelerate: The Science of Lean Software and DevOps. IT Revolution, 2018.

GITHUB. REST API documentation. https://docs.github.com/en/rest. Acesso em: 20 out. 2026.

SCIPY. Statistical functions. https://docs.scipy.org/doc/scipy/reference/stats.html. Acesso em: 20 out. 2026.

STATSMODELS. Multiple testing: multipletests. https://www.statsmodels.org/stable/generated/statsmodels.stats.multitest.multipletests.html. Acesso em: 20 out. 2026.

SCIKIT-LEARN. Model evaluation. https://scikit-learn.org/stable/modules/model_evaluation.html. Acesso em: 20 out. 2026.

WOHLIN, C. et al. Experimentation in Software Engineering. Springer, 2012. DOI: 10.1007/978-3-642-29044-2.