

Pontifícia Universidade Católica de Minas Gerais

Engenharia de Software

Medição e Experimentação de Software

Laboratório 02

Assistentes de IA vs. Codificação Manual

Participantes:

Fernanda Soares

Islayder Jackson

Vinicius Gomes

Professor: Danilo Maia

2026

2. Sumário

1. Capa
2. Sumário
3. Introdução
4. Objetivos
5. Questões de pesquisa
6. Metodologia
7. Participantes
8. Katas
9. Desenho experimental
10. Contrabalanceamento
11. Instrumentação
12. Métricas
13. RQ1 — Tempo até green
14. RQ2 — Resultado dos testes de aceitação
15. RQ3 — Estrutura do código
16. Inovação — Evolução por ciclos
17. Dashboard
18. Discussão
19. Ameaças à validade
20. Conclusão
21. Referências

3. Introdução

Este laboratório avaliou diferenças entre o uso de assistentes de inteligência artificial e a codificação manual em tarefas curtas de programação. O protocolo combinou testes de aceitação, limite temporal, registro de ciclos e métricas estruturais sobre o código final. Os resultados descrevem uma amostra pequena e não sustentam, isoladamente, inferências causais ou generalizações para outros contextos.

A análise final preserva a separação entre execuções instrumentadas, observações informadas pelo participante e artefatos estruturais mensuráveis. Tentativas inválidas e cenários históricos *SIM-** foram excluídos do conjunto analítico.

4. Objetivos

O objetivo geral foi comparar os tratamentos **IA** e **Manual** quanto ao tempo até uma solução verde, ao resultado dos testes de aceitação, à estrutura do código final e ao retrabalho observado ao longo dos ciclos.

Como objetivos específicos, buscou-se:

- mensurar tempo, testes e ciclos de cada trial final;

- comparar medidas centrais e dispersão entre tratamentos;
- coletar LOC, complexidade ciclomática e duplicação dos artefatos finais;
- registrar a evolução dos testes sem inventar ciclos ausentes;
- produzir resultados rastreáveis e regeneráveis a partir dos arquivos versionados.

5. Questões de pesquisa

- **RQ1 — Tempo:** o uso de assistente de IA altera o tempo até a solução ficar verde?
- **RQ2 — Defeitos/testes:** o tratamento altera o resultado final dos testes de aceitação?
- **RQ3 — Estrutura:** o tratamento altera LOC, complexidade ciclomática ou duplicação do código produzido?
- **Inovação:** como os testes evoluem entre ciclos e quanto retrabalho ocorre até o estado verde?

6. Metodologia

Cada participante resolveu quatro katas: dois com IA e dois manualmente. O runner criou workspaces isolados, protegeu os testes fornecidos, executou `pytest`, persistiu um registro por ciclo e encerrou cada trial em `green` ou no limite de 35 minutos. Para RQ1, RQ2 e inovação foram selecionados 12 trials finais, seis por tratamento. Duas tentativas inválidas de Vinicius e quatro cenários históricos `SIM-*` foram auditados e excluídos.

Os trials IA #21 e #25 de Islayder foram realizados com Gemini no celular, cronometrados durante a execução e informados pelo participante. Como não passaram pelo runner, seus campos observados ficam no arquivo separado `participant_reported_trials.csv`; a análise não fabrica timestamp, snapshot ou identificador de runner. O total de testes foi conferido diretamente nos testes de aceitação: 10 no Kata 1 e 9 no Kata 3.

Para RQ3 foram usados 12 arquivos `solucao.py` existentes, executáveis e mensuráveis. O coletor foi reexecutado sobre todos eles, e os resultados foram comparados aos registros consolidados. Nenhum registro `SIM-*` integra a análise final. Os registros `agent_delegated_codex_work` de Fernanda foram mantidos por corresponderem aos trials finais documentados, e não a fixtures simuladas.

7. Participantes

Tabela 1 — Distribuição dos trials finais por participante e tratamento.

Participante	Trials finais	IA	Manual
Fernanda Soares	4	2	2
Islayder Jackson	4	2	2
Vinicius Gomes	4	2	2
Total	12	6	6

Os três participantes contribuíram igualmente para a amostra. Portanto, nenhum participante domina numericamente um dos tratamentos.

8. Katas

Os quatro katas são funções puras em Python, sem dependências externas de produção.

Tabela 2 — Katas e quantidade real de testes de aceitação.

Kata	Identificador	Objetivo	Testes
1	kata1_normalizador_etiquetas	Normalizar e validar etiquetas	10
2	kata2_balanceamento_turnos	Balancear turnos	9
3	kata3_compactador_sensor	Compactar leituras de sensor	9
4	kata4_manutencao_preditiva	Priorizar manutenção preditiva	7

Os gabaritos de referência foram verificados isoladamente: 10/10, 9/9, 9/9 e 7/7 testes passaram. Eles não foram disponibilizados nos workspaces dos participantes.

9. Desenho experimental

O estudo adotou medidas repetidas: cada participante foi exposto aos dois tratamentos, sempre em katas diferentes. Cada trial iniciou a partir do stub do kata e terminou quando todos os testes passaram ou quando o time-box foi atingido. O desfecho principal foi o tempo até **green**; testes finais, ciclos e artefatos foram vinculados por participante, Issue, kata e tratamento.

Tabela 3 — Conjunto final dos 12 trials analisados.

Participante	Issue	Kata	Tratamento	Tempo (s)	Testes	Ciclos	Status
Fernanda	#19	Kata 2	IA	224,89	9/9	2	green
Fernanda	#27	Kata 1	Manual	63,20	10/10	2	green
Fernanda	#29	Kata 4	IA	74,02	7/7	2	green
Fernanda	#28	Kata 3	Manual	58,83	9/9	2	green
Islyder	#21	Kata 1	IA	75,00	10/10	1	green
Islyder	#24	Kata 2	Manual	127,17	9/9	1	green
Islyder	#25	Kata 3	IA	150,00	9/9	1	green
Islyder	#26	Kata 4	Manual	208,02	7/7	2	green
Vinicius	#22	Kata 1	IA	49,95	10/10	1	green
Vinicius	#30	Kata 2	Manual	365,99	9/9	1	green
Vinicius	#31	Kata 3	IA	324,52	9/9	1	green
Vinicius	#32	Kata 4	Manual	451,74	7/7	2	green

10. Contrabalanceamento

Islyder e Vinicius executaram a sequência Kata 1 IA, Kata 2 Manual, Kata 3 IA e Kata 4 Manual. Fernanda recebeu os tratamentos opostos e a ordem Kata 2 IA, Kata 1 Manual, Kata 4 IA e Kata 3 Manual.

Tabela 4 — Alocação dos tratamentos por participante e kata.

Participante	Kata 1	Kata 2	Kata 3	Kata 4
Fernanda	Manual	IA	Manual	IA
Islayder	IA	Manual	IA	Manual
Vinicius	IA	Manual	IA	Manual

Cada participante realizou dois trials por tratamento e cada kata apareceu nos dois tratamentos no conjunto. A alocação por kata é 2:1 devido ao número ímpar de participantes.

11. Instrumentação

O módulo `lab02/trials` implementa preparação, execução, time-box de 2.100 segundos, persistência atômica, snapshots finais, proteção dos testes e registro de ciclos. `trials.csv` e `trial_cycles.csv` preservam as execuções instrumentadas. Os dois trials IA de Islayder observados fora do runner permanecem no sidecar de dados informados pelo participante.

O coletor estrutural usa Radon 6.0.1 para LOC e complexidade e jscpd 5.2.0, com configuração versionada, para duplicação. Os scripts de análise geram tabelas intermediárias, figuras e dashboard a partir das fontes finais, permitindo repetição do processo.

12. Métricas

Tabela 5 — Definições operacionais das métricas.

Dimensão	Métrica	Definição operacional
RQ1	Tempo até green	Segundos decorridos até todos os testes passarem; trials no limite seriam censurados em 2.100 s
RQ2	Testes	Contagens absolutas passando, falhando e total, além da taxa final
Inovação	Ciclos	Número de execuções dos testes e primeiro ciclo em que ocorreu green
RQ3	LOC	Linhas lógicas de código (lloc) de <code>solucao.py</code>
RQ3	Complexidade	Média ciclomática por função/método e máximo do arquivo
RQ3	Duplicação	Percentual, linhas e blocos duplicados

Medianas, quartis e IQR usam a interpolação linear do Pandas. O teste de Wilcoxon foi aplicado às medianas individuais: para cada participante, a mediana dos dois tempos IA foi pareada à mediana dos dois tempos manuais.

13. RQ1 — Tempo até green

Tabela 6 — Estatísticas descritivas do tempo até green.

Tratamento	n	Média (s)	Mediana (s)	Q1 (s)	Q3 (s)	IQR (s)	Green	Censurados
IA	6	149,73	112,50	74,265	206,1675	131,9025	6	0
Manual	6	212,4917	167,595	79,1925	326,4975	247,305	6	0

Como mostra a Figura 1, a distribuição completa apresenta mediana e média menores em IA, mas também dispersão relevante nos dois tratamentos. Todos os 12 pontos são exibidos para que a pequena amostra permaneça visível.




Figura 1 — Distribuição do tempo até green por tratamento. A caixa representa $Q1-Q3$, a linha representa a mediana e os pontos representam os 12 trials.

Tabela 7 — Medianas de tempo por participante usadas no pareamento.

Participante	IA (s)	Manual (s)	Diferença IA – Manual (s)
Fernanda	149,455	61,015	88,440
Islayder	112,500	167,595	-55,095
Vinicius	187,235	408,865	-221,630

O Wilcoxon sobre os três pares resultou em $W = 2,0$ e $p = 0,75$. Portanto, a amostra apresentou menor tempo central em IA, mas não forneceu evidência estatística de diferença entre tratamentos. O pareamento é por participante e compara katas distintos, devendo ser interpretado com cautela.

A Figura 2 evidencia a heterogeneidade por participante: Fernanda teve mediana menor em Manual, enquanto Islayder e Vinicius tiveram mediana menor em IA.




Figura 2 — Medianas individuais de tempo por tratamento. As barras correspondem aos mesmos três pares usados no teste de Wilcoxon.

No recorte de Islayder, IA teve 75 s e 150 s, com média e mediana de 112,5 s e IQR de 37,5 s. Manual teve 127,17 s e 208,02 s, com média e mediana de 167,595 s e IQR de 40,425 s.

14. RQ2 — Resultado dos testes de aceitação

Tabela 8 — Resultado final dos testes por tratamento.

Tratamento	Trials	Green	Time-box	Testes passando	Falhando	Total	Taxa final mediana
IA	6	6	0	54	0	54	100%
Manual	6	6	0	51	0	51	100%

Todos os 105 testes finais passaram. Em Islayder, os resultados foram #21 10/10, #24 9/9, #25 9/9 e #26 7/7, todos green. Assim, **RQ2 não mostrou diferença no desfecho final de aceitação**: IA alcançou 54/54, Manual alcançou 51/51 e ambos tiveram zero falhas finais. A Figura 3 sintetiza essas contagens em pouco espaço.




Figura 3 — Resultado agregado dos testes finais. As anotações X/X preservam as contagens absolutas; o percentual é informação secundária.

A igualdade no estado final não implica trajetórias iguais. A evolução intermediária é analisada na seção de inovação.

15. RQ3 — Estrutura do código

Tabela 9 — Estatísticas estruturais dos 12 artefatos finais.

Tratamento	Métrica	n	Mediana	Q1	Q3	IQR
IA	LOC lógico	6	15,0	14,25	15,75	1,50
Manual	LOC lógico	6	11,0	10,25	12,50	2,25
IA	CC média	6	3,5	3,00	4,75	1,75
Manual	CC média	6	4,0	3,25	4,00	0,75
IA	Duplicação	6	0%	0%	0%	0%
Manual	Duplicação	6	0%	0%	0%	0%

Os 12 artefatos tiveram métricas completas e reproduzíveis. IA apresentou maior mediana de LOC, menor mediana de complexidade média e a mesma duplicação mediana do tratamento Manual. Com seis arquivos por grupo e katas heterogêneos, os resultados são descritivos e não demonstram efeito causal.

A Figura 4 revela dois pontos de LOC afastados das respectivas caixas — 27 LOC em IA e 5 LOC em outro artefato IA — que seriam ocultados por uma apresentação apenas por medianas.




Figura 4 — Distribuição de LOC lógico por tratamento, com todos os artefatos identificados por participante e kata.

A Figura 5 mostra mediana de complexidade média igual a 3,5 em IA e 4,0 em Manual. Os pontos tornam visível que IA também apresenta maior amplitude entre arquivos.




Figura 5 — Distribuição da complexidade ciclomática média por tratamento, com os 12 artefatos individuais.

A Figura 6 relaciona LOC e complexidade apenas para inspecionar conjuntamente as duas dimensões. Não foi calculada nem alegada correlação estatística.




Figura 6 — Relação exploratória entre LOC lógico e complexidade ciclomática média. Cor representa tratamento e forma representa participante.

Não há gráfico de duplicação porque todos os 12 artefatos apresentaram exatamente **0%**, com zero linhas e zero blocos duplicados; uma figura acrescentaria espaço sem informação comparativa.

Para Islayder, #21 apresentou 15 LOC, CC média 4,0, CC máxima 4, duplicação 0%, zero linhas/blocos duplicados e uma função; #25 apresentou 27 LOC, CC média 2,6667, CC máxima 4, duplicação 0%, zero linhas/blocos duplicados e três funções. Os testes desses artefatos passaram em 10/10 e 9/9, respectivamente.

Os snapshots originais apontados pelos trials finais de Fernanda não foram versionados. Seus quatro artefatos estruturais foram reconstruídos a partir de códigos preparatórios já presentes no repositório, passam nos testes e reproduzem as métricas consolidadas. Essa reconstrução preserva mensurabilidade, mas limita a equivalência de proveniência com os snapshots originais.

16. Inovação — Evolução por ciclos

Tabela 10 — Ciclos e taxa de aprovação por tratamento.

Tratamento	Trials	Ciclos — mediana	Intervalo de ciclos	Taxa mediana no 1º ciclo	Taxa mediana final
IA	6	1	1–2	100%	100%
Manual	6	2	1–2	14,285%	100%

A inovação do protocolo foi preservar o desempenho a cada execução de testes, permitindo observar progresso e retrabalho, e não apenas o estado final. A Figura 7 usa somente ciclos efetivamente registrados; trials de um ciclo aparecem como um único ponto.




Figura 7 — Evolução dos testes por trial e tratamento. As linhas ligam apenas ciclos observados do mesmo trial.

Como mostra a Figura 8, a mediana de IA atingiu o conjunto completo no primeiro ciclo; a mediana Manual precisou de dois ciclos. Em Islayder, #21, #24 e #25 ficaram verdes em um ciclo, e #26 evoluiu de 2/7 para 7/7 no segundo ciclo.




Figura 8 — Ciclo em que cada trial atingiu green. A figura preserva os 12 resultados individuais e diferencia os tratamentos por cor.

O resultado sugere menor retrabalho mediano com IA nesta amostra, sem estabelecer causalidade.

17. Dashboard

A Figura 9 resume 12 trials, três participantes, seis trials IA, seis trials Manual, medianas de 112,50 s e 167,595 s, 105/105 testes finais passando e 0% de duplicação. Os painéis compactos cobrem tempo, testes, ciclos, LOC, complexidade e a relação exploratória LOC × complexidade, evitando repetir o mesmo tipo de gráfico para dimensões distintas.

Lab02 — Assistentes de IA versus codificação Manual

RQ3: n=12 artefatos · observed=10 · agent_delegated_codex_work=2 · participantes: Fernanda, Islayder, Vinicius · SIM-* excluídos.

Figura 9 — Dashboard final das RQs e da inovação. Os KPIs no topo fixam o escopo e os desfechos agregados; os seis painéis preservam as distribuições essenciais.

Para reproduzir o dashboard na raiz do repositório:

```
.\.venv\Scripts\python.exe -m lab02.dashboard.build_dashboard
```

18. Discussão

Os resultados convergem em três pontos. Primeiro, IA teve tempos centrais menores, mas com alta dispersão e sem diferença estatisticamente detectável no Wilcoxon. Segundo, os dois tratamentos terminaram com todos os testes passando; a distinção mais visível ocorreu na trajetória, pois IA apresentou menos ciclos e maior taxa no primeiro ciclo. Terceiro, os códigos IA foram mais longos na mediana, ligeiramente menos complexos pela média ciclomática e igualmente sem duplicação detectada. Essas dimensões não devem ser combinadas em um único julgamento de qualidade.

O comportamento individual reforça a necessidade de cautela. Fernanda teve menor mediana temporal em Manual, enquanto Islayder e Vinicius tiveram menor mediana em IA. A direção agregada, portanto, não é uniforme entre participantes.

O relatório mantém separados trials finais, tentativas inválidas, fixtures históricas simuladas e observações informadas fora do runner. Essa separação evita aumentar artificialmente a amostra e permite rastrear a origem de cada resultado.

19. Ameaças à validade

- **Amostra:** três participantes e seis observações por tratamento limitam poder estatístico e generalização.
- **Heterogeneidade dos katas:** cada tratamento usa tarefas distintas para cada participante; diferenças de dificuldade podem se confundir com o tratamento.
- **Experiência e aprendizado:** familiaridade com Python, assistentes e katas pode afetar tempo, estratégia e ciclos; a ordem não elimina completamente o efeito de aprendizado.
- **Ferramenta de IA:** versões, interfaces e qualidade das respostas podem variar. Islayder usou Gemini no celular, enquanto dois registros de Fernanda têm proveniência `agent_delegated_codex_work`.
- **Ambiente e instrumentação:** os trials IA de Islayder foram cronometrados fora do runner e informados pelo participante; não possuem os mesmos timestamps e snapshots automáticos dos demais trials.
- **Proveniência estrutural:** os artefatos RQ3 de Fernanda são reconstruções testáveis de código já versionado, não os snapshots originais do runner.
- **Piloto:** o protocolo prescreve piloto temporal externo, mas não há evidência versionada de sua execução; isso limita a verificação independente da calibração dos katas.
- **Métricas:** LOC, complexidade e duplicação capturam apenas aspectos estruturais e não equivalem, isoladamente, a manutenibilidade ou qualidade global.

20. Conclusão

- **RQ1:** IA apresentou menor tempo médio e mediano, porém o Wilcoxon com três pares resultou em $p = 0,75$; não há evidência suficiente de diferença entre tratamentos.
- **RQ2:** IA e Manual alcançaram todos os testes finais, com 54/54 e 51/51, respectivamente; não houve diferença no desfecho final de aceitação.

- **RQ3:** IA teve maior LOC mediana (15 contra 11), menor CC média mediana (3,5 contra 4,0) e a mesma duplicação mediana (0%); o resultado é descritivo.
- **Inovação:** IA apresentou mediana de um ciclo e 100% dos testes no primeiro ciclo, enquanto Manual apresentou mediana de dois ciclos e 14,285% no primeiro; ambos terminaram em 100%.

O Lab02 está consolidado com 12 trials finais, 12 artefatos estruturais, análises regeneráveis, gráficos e dashboard coerentes. As conclusões permanecem proporcionais à amostra e às limitações documentadas.

21. Referências

- [Protocolo e instrumentação dos trials](#)
- [Definições e execução das análises](#)
- [Coletor e definições das métricas estruturais](#)
- [Relatório consolidado da Sprint 03](#)
- [Registro individual de Fernanda](#)
- [Registro individual de Islayder](#)
- [Registro individual de Vinicius](#)